



HUST

ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

ONE LOVE. ONE FUTURE.



ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

BÁO CÁO BÀI TẬP LỚN LƯU TRỮ VÀ XỬ LÝ DỮ LIỆU LỚN

ĐỀ TÀI:

Hệ thống lưu trữ, xử lý và phân tích dữ liệu chứng khoán Binance

GVHD: TS. Trần Việt Trung

Nhóm : 5

Mã lớp: 168482

ONE LOVE. ONE FUTURE.

Danh sách thành viên

Thành viên	MSSV
Lưu Quốc Dũng	20235302
Nguyễn Duy Liêm	20239750
Lê Hoàng Phúc	20235190
Nguyễn Khắc Nhất	20235391
Mai Tiến Hoàng	20235085

Nội dung chính

1. Giới thiệu bài toán
2. Tổng quan kiến trúc
3. Triển khai
4. Kết quả và bài học kinh nghiệm



1. Giới thiệu bài toán

1.1. Đặt vấn đề

1.2. Mục tiêu

1.3. Phạm vi



Đặt vấn đề

- Thị trường tiền mã hóa hoạt động liên tục 24/7, tạo ra lượng lớn dữ liệu giá, khối lượng và giao dịch theo thời gian thực.
- Việc theo dõi thủ công hoặc xử lý bằng công cụ truyền thống khó đáp ứng yêu cầu về tốc độ, tính liên tục và khả năng mở rộng.
- Vì vậy, cần một hệ thống Big Data có khả năng thu thập, xử lý, lưu trữ và cảnh báo dữ liệu crypto theo thời gian thực.

- Xây dựng nền tảng phân tích dữ liệu tiền mã hóa tự động, từ thu thập dữ liệu Binance đến xử lý streaming, lưu trữ và trực quan hóa.
- Ứng dụng Kafka, Spark Structured Streaming, MinIO/Delta Lake và MongoDB để xây dựng pipeline dữ liệu theo mô hình Bronze – Silver – Gold – Alerts.
- Cung cấp dashboard và hệ thống cảnh báo giúp người dùng theo dõi biến động thị trường, tín hiệu xử lý và các sự kiện bất thường.



2. Tổng quan kiến trúc

2.1. Data Ingestion Layer

2.2. Messaging Layer

2.3. Processing & Lakehouse Layer


2.4. Serving & Alert Layer

2.5. Visualization & Monitoring Layer

2.6. Machine Learning Pipeline




Tổng quan kiến trúc



2.1 Chi tiết Data Ingestion Layer

Vai trò:


- Thu thập dữ liệu từ Binance API
- Hỗ trợ WebSocket realtime và REST/backfill
- Đẩy dữ liệu vào Kafka topics
- Là đầu vào cho Spark Streaming



2.1 Chi tiết Data Ingestion Layer

Luồng hoạt động:


1. Khởi động service và đọc biến môi trường
2. Backfill dữ liệu lịch sử khi startup
3. Duy trì WebSocket để đẩy dữ liệu realtime vào Kafka



2.2 Chi tiết Messaging Layer

Vai trò Kafka:


- Kafka là tầng trung gian giữa Ingestion Service và Spark Streaming.
- Nhận dữ liệu realtime/backfill từ Binance thông qua ingestion-service.
- Phân loại dữ liệu vào các topic: raw-crypto-ticks, raw-ohlc, raw-orderbook.
- Tách rời producer và consumer, giúp hệ thống dễ mở rộng.



2.2 Chi tiết Messaging Layer

Luồng hoạt động:


1. kafka service khởi động ở chế độ KRaft, không dùng Zookeeper.
2. kafka-init đợi Kafka healthy rồi tạo các topic cần thiết.
3. -ingestion-service chỉ chạy sau khi kafka-init hoàn tất.
4. Các service sau đó giao tiếp qua địa chỉ nội bộ kafka:29092.



2.3 Chi tiết Processing & Lakehouse Layer


Vai trò :

- Spark Structured Streaming đọc dữ liệu từ Kafka.
- Xử lý dữ liệu theo luồng Bronze → Silver → Gold → Alerts.
- MinIO đóng vai trò Data Lake/S3 storage.
- Delta Lake hỗ trợ lưu trữ dữ liệu có cấu trúc và checkpoint.



2.3 Chi tiết Processing & Lakehouse Layer

Luồng hoạt động:



2.3 Chi tiết Processing & Lakehouse Layer

Overview: Xử lý dữ liệu streaming và xây dựng Data Lakehouse phục vụ phân tích

Công nghệ sử dụng

Apache Spark Structured Streaming

- Xử lý dữ liệu liên tục từ Kafka
- Micro-batch processing
- Hỗ trợ Exactly-once với checkpoint

Delta Lake + MinIO/S3

- Lưu trữ dữ liệu lớn dạng Lakehouse
- Hỗ trợ ACID Transaction
- Quản lý dữ liệu theo phiên bản

Medallion Architecture

- Bronze → Silver → Gold
- Tăng dần chất lượng dữ liệu



2.3 Chi tiết Processing & Lakehouse Layer

Bronze Layer: Raw Data Storage

Mục đích:

- Lưu dữ liệu gốc từ Kafka
- Giữ lịch sử dữ liệu
- Cho phép replay khi cần

Sliver Layer: Cleaned & Enriched Data

Các bước xử lý:


- Deduplication → Loại dữ liệu trùng
- Type Casting → String → Numeric
- Validation → Kiểm tra dữ liệu lỗi
- Timestamp Processing
- Technical Indicators (chỉ báo)

Gold Layer: Chuẩn bị dữ liệu phục vụ DashBoard & Alert Engine

Mục đích:

- Lưu dữ liệu gốc từ Kafka
- Giữ lịch sử dữ liệu
- Cho phép replay khi cần

2.3 Chi tiết Processing & Lakehouse Layer



2 nhóm chỉ số tính toán:

- **Nhóm chỉ số thị trường (*real-time metrics*):**
 - + OHLCV 1-phút: Tính toán giá OHLCV mỗi phút.
 - + Average Price & Trade Count: Tính giá trung bình và số lượng giao dịch phát sinh
 - + Price Volatility: Mức độ biến động tức thời.
- **Nhóm chỉ số cảnh báo (*Real-time Alerts*):**
 - + Return Percentage: Cảnh báo khi giá biến động vượt ngưỡng.
 - + Range Percentage: Cảnh báo khi biên độ bất thường
 - + Direction & Scoring: Phân loại hướng biến động (Lên/Xuống) và chấm điểm mức độ nghiêm trọng của biến động để ưu tiên xử lý.

Chi tiết Streaming Layer

Vai trò:

- **Xử lý dữ liệu tức thời (Low Latency):** Tiếp nhận luồng dữ liệu liên tục từ Kafka, phục vụ các Dashboard giám sát trực tiếp.
- **Phát hiện bất thường (Anomaly Detection):** Tự động lọc và nhận diện các hành vi giá bất thường thông qua cơ chế Alerting, giúp nhà đầu tư phản ứng kịp thời với các cú sốc thị trường.
- **Cơ chế Watermarking:** Xử lý dữ liệu đến muộn, đảm bảo tính chính xác của các chỉ số thống kê trong môi trường mạng không ổn định.

Công nghệ

- **Spark Structured Streaming:** Xử lý dữ liệu streaming và nhận diện các biến động bất thường.
- **Spark Checkpointing:** Quản lý trạng thái (State management) và đảm bảo khả năng phục hồi lỗi (Fault Tolerance) cho luồng dữ liệu liên tục.

2.4 Chi tiết Serving & Alert Layer

Overview: Cung cấp dữ liệu phân tích và tín hiệu giao dịch cho người dùng cuối

Thành phần chính:

FastAPI – Alert Engine API


- Quản lý Alert Rules
- Cung cấp REST API cho Dashboard
- Xử lý request bất đồng bộ (async)

MongoDB: Lưu dữ liệu phục vụ truy vấn nhanh

- Alert Rules
- Alert Events
- Gold Analytics Data


Dashboard

- Hiển thị dữ liệu thị trường
- Theo dõi chỉ báo kỹ thuật



2.4 Chi tiết Serving & Alert Layer

Real-time Alert: Tự động phát hiện tín hiệu giao dịch dựa trên rule người dùng



Các tín hiệu hỗ trợ:

- BUY
- SELL
- WATCH

Dựa trên:

- RSI
- MACD
- Volume Ratio
- Candle Pattern

2.4 Chi tiết Serving & Alert Layer

Cấu trúc chỉ mục


Index name	Mục đích	Source
stock-realtime-1m	Lưu trữ chỉ số OHLCV, giá trung bình và độ biến động mỗi 1 phút	Streaming job
stock-alerts-1m	Lưu trữ các bản ghi vi phạm ngưỡng cảnh báo (tăng/giảm > 1%)	Streaming Alert Job
batch-features	Lưu trữ các chỉ số kỹ thuật chuyên sâu (Long-term Trend, Drawdown, Market Regime...) phục vụ phân tích lịch sử và Dashboard tổng hợp.	Batch jobs

2.4 Chi tiết Serving & Alert Layer

Vai trò:

- **Tối ưu hóa truy vấn tốc độ cao:** Cho phép tìm kiếm và lọc dữ liệu trên hàng triệu bản ghi với độ trễ tính bằng mili giây
- **Điểm truy cập dữ liệu thống nhất:** Người dùng hoặc ứng dụng bên thứ ba (Dashboard) chỉ cần kết nối tới Serving Layer để lấy được cả chỉ số realtime và chỉ số lịch sử
- **Trực quan hóa dữ liệu:** Xây dựng các biểu đồ đường, biểu đồ nến và các bảng cảnh báo thời gian thực, giúp nhà đầu tư đưa ra quyết định nhanh chóng.
- **Đảm bảo tính nhất quán:** Sử dụng cơ chế doc_id (kết hợp ticker và timestamp) để đảm bảo dữ liệu không bị trùng lặp khi các job Spark thực hiện ghi đè hoặc cập nhật lại.

2.5 Kết quả Visualization




2.5 Kết quả Visualization

[Crypto Alert] BUY Signal – BTCUSDT Hộp thư đến x



Crypto Analytics <luudungpkt922005@gmail.com>
đến tôi ▾

17:17 Thứ 5, 28 thg 5 (13 ngày trước) ☆ 😊 ↶ ⋮



↶ Trả lời

↷ Chuyển tiếp




2.6 Machine Learning Pipeline

Machine Learning Module

- Bài toán: Dự đoán xu hướng giá BTCUSDT (UP / DOWN)
- Dữ liệu: OHLCV + technical indicators (5 phút)
- Kiểu bài toán: Binary classification + time-series

Pipeline ML:



2.6 Machine Learning Pipeline

Kết quả thực nghiệm

So sánh các mô hình

Mô hình	Accuracy
Logistic Regression	~ 0.81
Random Forest	~ 0.81
XGBoost	~ 0.77

2.6 Machine Learning Pipeline

Nhận xét chính (Key Observations)

- Logistic Regression và Random Forest:
 - Có xu hướng lệch về lớp chiếm đa số (DOWN)
- XGBoost:
 - Cân bằng hơn giữa hai lớp
 - Hoạt động ổn định hơn trên dữ liệu tài chính có nhiễu cao
- Accuracy không phản ánh đầy đủ chất lượng mô hình trong bài toán này

Kết luận

XGBoost là mô hình ổn định nhất cho bài toán dữ liệu tài chính dạng chuỗi thời gian này.



HUST

3. Triển khai

Môi trường triển khai với Docker và K8s


Docker

Ưu điểm

- Dễ học, triển khai nhanh
- Nhẹ, chạy tốt cho dev/test
- Đóng gói ứng dụng hiệu quả

Nhược điểm

- Không auto-scale
- Không HA (high availability)
- Không phù hợp hệ thống lớn



Kubernetes (K8s)

Ưu điểm

- Quản lý container quy mô lớn
- Auto-scale, self-healing
- HA, load balancing
- Phù hợp production

Nhược điểm

- Phức tạp, nhiều YAML
- Khó học, tốn tài nguyên
- Overkill cho app nhỏ



Kubernetes trên Docker Desktop

The screenshot shows the Docker Desktop interface with the Kubernetes tab selected. The left sidebar contains navigation options: Gordon (BETA), Containers, Images, Volumes, Kubernetes (selected), Builds, Models, MCP Toolkit (BETA), Docker Hub, Docker Scout, and Extensions. The main area displays the 'Kubernetes' section with a 'Namespace' dropdown set to 'crypto-analytics'. Below this, there are four panels: 'Cluster', 'Deployments', 'Nodes', and 'Pods'. The 'Cluster' panel shows one active cluster of type 'kind' with 1 node and Kubernetes version v1.34.3. The 'Deployments' panel lists six deployments: spark-master, spark-worker, spark-unified-streaming, ingestion-service, and alert-ani, all in 'Available' status. The 'Nodes' panel shows one node named 'desktop-control-plane' in 'Ready' status. The 'Pods' panel lists six pods: kafka-init-b6jxl, minio-init-7h7k5, mongo-seed-8w4zp, spark-master-84f7cf696f-wxsmb, and spark-worker-6bc8c7fc74-tpm8g, with statuses ranging from 'Succeeded' to 'Running'. At the bottom, a status bar shows 'Engine running' and system resources: RAM 7.32 GB, CPU 2.76%, and Disk 59.44 GB used (limit 1006.85 GB). A 'Terminal' button and 'Update available' link are also visible.

Kubernetes Give feedback

Namespace: crypto-analytics

Cluster Stop Edit cluster

Cluster	Cluster type	Nodes	Kubernetes version
Active	kind	1	v1.34.3

Deployments

Name	Status	Pods
spark-master	Available	1/1
spark-worker	Available	1/1
spark-unified-streaming	Available	1/1
ingestion-service	Available	1/1
alert-ani	Available	1/1

Nodes

Name	Status
desktop-control-plane	Ready

Pods

Name	Status
kafka-init-b6jxl	Succeeded
minio-init-7h7k5	Succeeded
mongo-seed-8w4zp	Succeeded
spark-master-84f7cf696f-wxsmb	Running
spark-worker-6bc8c7fc74-tpm8g	Running

Services

Name	Cluster IP	Ports
kafka	None	29092/TCP,9092/TCP,9093/TCP
mongodb	10.96.154.53	27017/TCP

Upgrade plan

Engine running | Kubernetes running RAM 7.32 GB CPU 2.76% Disk: 59.44 GB used (limit 1006.85 GB) Terminal Update available

Hướng phát triển

- Chuyên nghiệp hóa vận hành: Ứng dụng Apache Airflow để quản lý và theo dõi Pipeline tự động (DAGs).
- Tối ưu hóa Cloud: Triển khai trên Managed Services (GKE, Dataproc) và phân cấp lưu trữ (Hot/Cold storage) để giảm chi phí.
- Mở rộng dữ liệu: Tích hợp phân tích tâm lý thị trường (Sentiment Analysis) từ mạng xã hội và tin tức tài chính.
- Cảnh báo đa kênh: Tự động gửi thông báo biến động thêm qua Telegram, Slack.

Demo

A large, stylized graphic of the HUST logo, composed of many small red dots arranged in a circular pattern, filling the left half of the slide.

HUST

THANK YOU !

